


AGENTRL: Scaling Agentic Reinforcement Learning with a Multi-Turn, Multi-Task Framework

Hanchen Zhang^{1†}, Xiao Liu^{1,2*}, Bowen Lv^{1†}, Xueqiao Sun¹, Bohao Jing^{2†},
Jat Long Jong^{1†}, Zhenyu Hou^{1†}, Zehan Qi^{1†}, Hanyu Lai^{1†}, Yifan Xu^{1†}, Rui Lu^{1†},
Hongning Wang¹, Jie Tang¹, Yuxiao Dong¹

¹ Tsinghua University ² Z.AI

Abstract

Recent advances in large language models (LLMs) have sparked growing interest in building generalist agents that can learn through online interactions. However, applying reinforcement learning (RL) to train LLM agents in multi-turn, multi-task settings remains challenging due to lack of scalable infrastructure and stable training algorithms. In this work, we present the AGENTRL framework for scalable multi-turn, multi-task agentic RL training. On the infrastructure side, AGENTRL features a fully-asynchronous generation-training pipeline for efficient multi-turn RL. To support heterogeneous environment development in multi-task RL, we design a unified function-call based API interface, containerized environment development, and a centralized controller. On the algorithm side, we propose cross-policy sampling to encourage model exploration in multi-turn settings and task advantage normalization to stabilize multi-task training. Experiments show that AGENTRL, trained on open LLMs across five agentic tasks, significantly outperforms GPT-5, Claude-Sonnet-4, DeepSeek-R1, and other open-source LLM agents. Multi-task training with AGENTRL matches the best results among all task-specific models. AGENTRL is open-sourced at <https://github.com/THUDM/AgentRL>. The algorithm and framework are adopted in building AUTOGLM (Liu et al., 2024b).



(a) Gains of AGENTRL over the base (32B). (b) RL progress of AGENTRL (32B).

Figure 1: Overall performance of AGENTRL.

AgentRL: 构建可扩展的多轮、多任务智能体强化学习框架



熵基跃迁

关注他

📖 收录于 · 论文

22 人赞同了该文章

论文: AgentRL: Scaling Agentic Reinforcement Learning with a Multi-Turn, Multi-Task Framework

一、简介

近年来,大型语言模型 (LLMs) 的迅猛发展激发了学术界与工业界对构建通用人工智能体 (Generalist Agents) 的浓厚兴趣。强化学习 (Reinforcement Learning, RL), 特别是从人类反馈中学习 (RLHF) 以及近期从可验证奖励中学习 (RLVR) 的技术, 已被证明是优



然而，当我们试图将这一范式从简单的“单次问答”推向构建能够在复杂、动态环境中持续交互的真正“智能体”时，面临着两大严峻的挑战：

- **多轮次交互⁺ (Multi-Turn Interaction)**: 智能体任务要求模型在一系列连续的步骤中与环境交互，这导致了巨大的状态空间和极低的训练效率。
- **多任务学习 (Multi-Task Learning)**: 构建一个“通用”智能体，需要其能同时掌握多种异构任务，但这极易引发任务间的相互干扰，导致训练不稳定和性能下降。

现有研究大多局限于为单一任务训练专用模型，而在通往可扩展、稳定的多轮次、多任务智能体 RL 的道路上，仍缺乏成熟的**基础设施**和**鲁棒的训练算法**。

为应对上述挑战，本文提出了 **AGENTRL**，一个专为规模化智能体强化学习设计的**多轮次、多任务框架**。AGENTRL 的核心贡献在于，它从基础设施和算法两个层面提供了一套协同的解决方案，旨在扫清通往通用智能体的障碍。

二、Agentic RL 的问题与挑战

1. 从单轮响应到多轮交互的范式转变

传统的强化学习应用于大型语言模型 (LLMs)，其交互模式本质上是**单轮次 (Single-Turn)** 的。模型接收一个提示 (prompt)，生成一个响应，然后根据这个响应的好坏获得一个一次性的奖励信号。这种模式更像一个复杂的“多臂老虎机”问题，模型需要学会在给定状态下做出最佳的单次决策。

然而，构建一个真正的“智能体” (Agent) 要求迈向一个更复杂的范式：**多轮次 (Multi-Turn)** 动态交互，称之为**智能体强化学习 (Agentic RL)**。在这个范式下，LLM 不再是一个被动的响应生成器，而是一个主动的**自主决策者**。它需要：

- **执行一系列动作**：与外部环境（如操作系统、数据库、网页）进行连续的、有状态的交互。
- **处理中间反馈**：根据每一步动作产生的结果，动态调整后续的策略。
- **完成长期目标**：整个交互过程（即轨迹，trajectory）的最终目标是最大化累积奖励。

2. 问题的形式化定义

可以将 Agentic RL 任务建模为一个**马尔可夫决策过程⁺ (Markov Decision Process, MDP)**，其定义为一个元组 $\mathcal{T} = (\mathcal{S}, \mathcal{A}, \mathcal{P}, r, \rho)$ ：

- **状态空间 $\mathcal{S}$ (State Space)**: 在 LLM Agent 的场景下，状态是复合的。它不仅包含外部环境的状态 s^{env} （例如，当前网页的界面），还包含了到目前为止的交互历史 s^{ctx} （即对话上下文）。
- **动作空间 $\mathcal{A}$ (Action Space)**: 动作通常是 LLM 生成的文本或结构化指令（如函数调用），用于与环境交互。
- **转移概率 $\mathcal{P}$ (Transition Probability)**: $\mathcal{P}(s'_{t+1} | s_t, a_t)$ 描述了在状态 s_t 执行动作 a_t 后，环境转移到新状态 s'_{t+1} 的概率。在 Agentic RL 中，这个转移过程是**非平凡的 (non-trivial)**，它驱动着整个任务的进展。
- **奖励函数 r (Reward Function)**: $r(s_t, a_t)$ 定义了在执行动作后获得的即时奖励。
- **初始状态分布 ρ (Initial State Distribution)**: 描述了任务开始时的状态分布。

与此相对，单轮次任务可以视为是这个模型的一个特例，其中状态转移 $\mathcal{P}$ 是平凡的，因为交互在

构建一个能够胜任多种任务的通用智能体 (Generalist Agent)，总归有个以多任务为目标的难题，还必须应对多任务环境的复杂性。这构成了 Agentic RL 的两大核心挑战，具体可以从**基础设施 (Infrastructure)** 和**算法 (Algorithm)** 两个层面进行剖析。

维度	挑战层面	单轮次	多轮次
单任务	基础设施	可采用同步 rollout，实现简单。	- 效率瓶颈: 同步模式导致严重 GPU 闲置（等待长轨迹生成），异步架构成为刚需。 - 环境扩展: 大规模部署交互式环境的成本和管理难度高。
	算法	核心在于训练的稳定性和可扩展性。	- 探索困境: 状态空间呈爆炸式增长，需要更高效的探索策略。 - 探索衰减: 训练后期模型策略收敛，探索能力自然下降，易陷入局部最优。
多任务	基础设施	- 异构性挑战: 需要统一不同接口、依赖和资源需求的异构环境，集成难度大。	(继承并放大了单任务、多轮次的所有基础设施挑战)
	算法	- 任务间干扰: 不同任务的梯度方向或奖励尺度可能冲突，导致负迁移 (negative transfer)。	- 学习失衡: 不同任务的难度和学习速度差异巨大，导致训练不稳定。

3.1 从单轮到多轮

基础设施层面：在多轮交互中，生成一条完整轨迹的时间可能从几秒到数分钟不等。如果采用同步模式，处理快任务的 GPU 必须空闲等待处理慢任务的 GPU，这造成了巨大的资源浪费，即所谓的“流水线气泡 (pipeline bubbles)”。因此，一个高效的**异步训练+框架**是实现规模化 Agentic RL 的前提。

算法层面：多轮交互的轨迹更长，决策路径呈指数级增长。这不仅要求模型具备更强的探索能力以发现有效的解决方案，同时也加剧了“模型坍塌 (model collapse)”的风险——即模型过度依赖自身生成的有限数据，导致多样性丧失和能力退化。

3.2 从单任务到多任务

基础设施层面：现实世界的任务是**异构的**。例如，Webshop 环境需要浏览器引擎，而 DB 环境需要数据库连接。它们的依赖、API 接口、资源消耗 (CPU/内存) 各不相同。设计一个能够无缝集成、调度和管理这些异构环境的通用平台，是实现通用智能体训练的关键瓶颈。

算法层面：当一个模型同时学习多个任务时，一个核心问题是如何平衡不同任务的学习过程。如果一个任务的奖励信号远远强于另一个，或者学习梯度方向冲突，模型可能会“牺牲”一个任务的性能来优化另一个，导致整体性能下降和训练不稳定。因此，需要专门的算法来**缓解任务间的干扰**并稳定优化过程。

1. 解决多轮次挑战

多轮次 Agentic RL 的核心难题在于**效率**和**探索**。轨迹生成耗时长导致训练效率低下，而巨大的状态空间则要求更智能的探索策略。AGENTRL 通过以下设计来应对。

1.1 基础设施：异步训练




Figure 3: Synchronous vs. Asynchronous Training. The asynchronous design improves efficiency by separating data rollout and model training on different resource groups.

同步训练模式下，GPU 需等待整个批次（batch）的数据全部生成完毕才能开始训练。由于多轮次任务的轨迹长度差异巨大，这导致了严重的 GPU 闲置和低效。

将“数据生产”（Rollout）和“数据消费”（Training）解耦。想象一条生产线，生产者（Rollout 引擎）持续不断地将产品（生成的轨迹数据）放入一个共享仓库，而消费者（Training 引擎）则根据自己的节奏随时从仓库中取货进行加工。这样，任何一方都不需要等待另一方，从而最大化整体效率。

AgentRL 将 Rollout 和 Training 部署在**独立的计算资源组**上，通过一个数据队列进行异步通信。**协程调度与动态批处理 (Coroutine Scheduling & Dynamic Batching)**: 训练模块不再要求固定的批大小。它采用协程调度机制，在每次模型更新后，立即从数据队列中拉取当前所有可用的数据，形成一个**动态大小的批次**进行训练。

如图 3 所示，这种设计消除了“流水线气泡”，允许训练和生成过程无缝衔接。

1.2 算法：跨策略采样⁺




Figure 6: Different rollout strategies. In *single* model generation, all steps of all traces are generated by the same model. In *mix* mode, half of the samples are generated by each model. In *cross-policy* mode, all samples are generated with cross-policy sampling strategy.

知乎 @熵基跃迁

在漫长的 RL 训练过程中，模型策略会逐渐收敛，导致其探索行为减少，容易陷入已知的高奖励区域而错过潜在更优的解法。这个问题在多轮次任务的巨大状态空间中尤为突出，也与“模型坍塌 (Model Collapse)”现象密切相关。

单个模型（或单一策略）的视野是有限的。如果能在一个决策过程中，汇集多个不同“思维方式”的模型智慧，就有可能跳出单一模型的认知局限，探索到更广阔的状态空间。

AgentRL 在生成单条轨迹的过程中，**每一步 (step)** 的动作并非由固定的一个模型生成，而是从一个**模型池 (pool of models)** 中随机选择一个模型来生成。为了实践上的便利性，AgentRL 采用了一种巧妙的近似方法。它维护一组 Rollout 引擎，其中一部分引擎使用最新的模型参数，而另一部分则使用模型的**早期检查点 (stale checkpoints)**。这样，在生成轨迹的每一步，动作可能来自当前最优策略，也可能来自一个“过去”的、具有不同行为偏好的策略。

如图 6 所示，这种方法聚合了不同策略的探索路径。它不仅增加了轨迹的多样性，更重要的是，它有能力探索到**任何单个策略都无法独立发现的**、通往成功的“蹊径”，同时保证了每一步生成的语言和动作在语法上是有效的，避免了无意义的探索。

2. 解决多任务挑战

多任务学习的目标是训练一个通用模型，其核心挑战在于如何**整合异构环境并稳定优化过程**，避免任务间的相互干扰。

2.1 基础设施：统一接口与中心化控制




Figure 5: The AGENTRL training pipeline, decoupled into a Training Framework and an Environment Deployment Framework, organized by a central AGENTRL Controller. The Training Framework is responsible for policy rollouts and updates, while the Environment Deployment Framework manages scalable, containerized task environments that provide feedback.

不同的智能体任务环境（如操作系统、数据库）拥有截然不同的接口、依赖和运行方式。如何将它们高效、可扩展地集成到同一个训练框架中是一个巨大的工程挑战。建立一套“标准化”的协议。无论后端环境多么复杂，都通过一个统一的、标准化的“插座”（API）暴露给上层应用。同时，需要一个“中央调度中心”来统一管理所有接入的设备。AgentRL的实现：

- **统一的函数调用接口 (Unified Function-call API):** AgentRL 为所有环境定义了一套基于函数调用的标准 API。这屏蔽了底层环境的实现细节，使得训练引擎可以用同样的方式与任何环境进行交互。
- **容器化部署 (Containerized Deployment):** 每个环境都被封装在独立的容器中，实现了资源隔离和环境隔离，便于大规模部署和管理。
- **中心化控制器 (Centralized Controller):** 如图 5 所示，一个高性能的中心化控制器负责管理所有环境容器的生命周期、任务分发和状态监控，为上层的 RL 训练引擎提供了一个统一、透明的多任务执行视图。

2.2 算法：任务优势归一化⁺

在多任务训练中，不同任务的奖励尺度、轨迹长度和学习难度差异巨大。例如，一个简单任务的优势值 (Advantage) 可能总是在 $[0, 1]$ 之间，而一个复杂任务的优势值可能在 $[-10, 10]$ 之间波动。这会导致优化器在更新模型时，被优势值绝对值更大的任务所“主导”，从而忽略其他任务，造成学习失衡和训练不稳定。

对不同任务的“绩效评价标准”进行统一。无论原始分数的范围如何，都将它们转换到一个标准的、可比较的尺度上（例如，都转换为标准正态分布），这样优化器就能公平地对待每个任务的贡献。

在计算完一个批次中所有数据的优势估计后，**按任务 (per-task)** 对这些优势值进行归一化。对于一个 LLM 策略，其动作 a_t 由一系列 token $y_{t,k}$ 组成。我们首先计算出每个 token 级别的优势估计 $\hat{A}_{i,s,g,t,k}$ 。然后，对每个任务 i 在当前批次内的所有 token 优势进行标准化处理：

$$\tilde{A}_{i,s,g,t,k} = \frac{\hat{A}_{i,s,g,t,k} - \mu_i}{\sigma_i} \quad \dots \quad (1)$$

- $\tilde{A}_{i,s,g,t,k}$ ：归一化后的 token 级优势。
- $\hat{A}_{i,s,g,t,k}$ ：原始的 token 级优势，其中 i 是任务索引， s, g, t, k 分别代表样本、轨迹、步骤和 token 的索引。
- μ_i ：任务 i 在当前批次内所有 token 优势的均值。
- σ_i ：任务 i 在当前批次内所有 token 优势的标准差。

四、

1.1 任务与环境

实验环境涵盖了五种具有代表性的多轮交互智能体任务，这些任务均基于 **AGENTBENCH-FC** 进行了适配，具体如下：

任务名称 (Task Name)	核心能力考察 (Core Skills Tested)
ALFWorld	文本冒险游戏中的常识推理与长期规划能力。
DB	将自然语言转换为 SQL 查询的数据库操作能力。
KG	在大型知识图谱中进行多步推理与信息整合的能力。
OS	通过命令行 (Bash) 与操作系统交互的工具使用能力。
WebShop	在模拟购物网站中进行信息检索、筛选和决策的能力。

1.2 基线

模型类别 (Model Category)	代表模型 / 系列 (Representative Models / Series)
基线 - 闭源 API	Claude-Sonnet 系列, GPT-5, o-series
基线 - 开源模型 (Prompting)	DeepSeek-V3, DeepSeek-R1, Qwen2.5-Instruct 系列
基线 - 开源模型 (Agent Training)	Hephaestus, AgentLM 系列
AGENTRL 训练对象	Qwen2.5-Instruct 系列 (3B, 7B, 14B, 32B), GLM-4-9B

2. 主要结果

2.1 性能

Model	ALFWorld	DB	KG	OS	Webshop	AVG
API LLMs (Prompting)						
Claude-Sonnet-3.7 (2025-02-19)	61.1 $\pm$ 3.0	68.5 $\pm$ 0.8	59.8 $\pm$ 1.0	36.5 $\pm$ 4.1	40.1 $\pm$ 1.5	53.2
Claude-Sonnet-3.7 Thinking (2025-02-19)	54.1 $\pm$ 3.0	68.4 $\pm$ 0.3	38.2 $\pm$ 2.2	53.1 $\pm$ 1.8	36.0 $\pm$ 1.7	50.0
Claude-Sonnet-4 (2025-05-14)	73.6 $\pm$ 2.6	70.1 $\pm$ 0.7	63.4 $\pm$ 1.7	45.3 $\pm$ 2.8	34.6 $\pm$ 1.6	57.4
Claude-Sonnet-4 Thinking (2025-05-14)	69.0 $\pm$ 3.2	68.4 $\pm$ 1.0	64.4 $\pm$ 1.9	51.0 $\pm$ 2.3	38.3 $\pm$ 2.8	58.2
GPT-4o (2024-11-20)	28.3 $\pm$ 2.8	54.3 $\pm$ 2.2	49.3 $\pm$ 2.7	38.5 $\pm$ 3.2	27.8 $\pm$ 2.2	39.6
o3-mini (2025-01-31)	28.4 $\pm$ 1.3	56.5 $\pm$ 0.5	51.8 $\pm$ 0.9	35.1 $\pm$ 1.7	32.7 $\pm$ 1.5	40.9
o4-mini (2025-04-16)	32.6 $\pm$ 1.8	63.4 $\pm$ 0.3	32.4 $\pm$ 3.0	41.8 $\pm$ 1.0	28.5 $\pm$ 1.8	39.7
GPT-5 (2025-08-07)	65.4 $\pm$ 2.0	63.2 $\pm$ 0.7	64.1 $\pm$ 1.8	34.5 $\pm$ 1.0	33.7 $\pm$ 2.6	52.2
Open LLMs (Prompting)						
DeepSeek-V3 (2025-03-24)	31.9 $\pm$ 2.0	58.4 $\pm$ 1.2	14.0 $\pm$ 2.0	53.0 $\pm$ 1.0	23.4 $\pm$ 2.5	36.1
DeepSeek-R1 (2025-05-28)	51.4 $\pm$ 4.1	60.4 $\pm$ 0.5	50.2 $\pm$ 2.7	53.6 $\pm$ 1.0	31.0 $\pm$ 1.6	49.3
Qwen2.5-14B-Instruct	8.7 $\pm$ 3.1	48.4 $\pm$ 2.2	35.3 $\pm$ 3.0	26.0 $\pm$ 3.1	17.6 $\pm$ 1.0	27.2
Qwen2.5-32B-Instruct	32.1 $\pm$ 3.9	55.8 $\pm$ 0.6	33.8 $\pm$ 1.5	37.0 $\pm$ 1.5	27.5 $\pm$ 2.3	37.2
Qwen2.5-72B-Instruct	47.5 $\pm$ 3.3	45.3 $\pm$ 0.9	26.5 $\pm$ 3.1	49.5 $\pm$ 3.5	35.4 $\pm$ 2.7	40.8
Open LLMs (Agent Training)						
Hephaestus-8B-Base	30.0	32.3	16.0	20.8	60.5*	31.9
Hephaestus-8B-IFT	46.0	29.7	21.2	20.8	63.9*	36.3
AgentLM-7B	84.0	30.6	18.1	17.4	63.6*	42.7
AgentLM-13B	76.0	33.7	26.8	18.1	70.8*	45.1
AgentLM-70B	86.0	37.7	47.0	21.5	64.9*	51.4
AGENTRL						
w/ Qwen2.5-3B-Instruct	92.4 $\pm$ 0.5	60.0 $\pm$ 1.1	55.0 $\pm$ 2.0	40.5 $\pm$ 0.9	52.1 $\pm$ 0.9	60.0
w/ Qwen2.5-7B-Instruct	91.5 $\pm$ 0.9	63.7 $\pm$ 0.5	57.8 $\pm$ 2.3	40.8 $\pm$ 1.2	56.1 $\pm$ 0.6	62.0
w/ Qwen2.5-14B-Instruct	91.5 $\pm$ 0.9	72.2 $\pm$ 0.9	72.8 $\pm$ 1.8	43.6 $\pm$ 1.9	58.5 $\pm$ 1.2	67.7
w/ Qwen2.5-32B-Instruct	94.5 $\pm$ 0.5	70.4 $\pm$ 0.5	77.0 $\pm$ 1.2	51.7 $\pm$ 1.8	58.6 $\pm$ 0.9	70.4
w/ GLM-4-9B-0414	93.3 $\pm$ 0.5	66.9 $\pm$ 0.4	75.7 $\pm$ 1.8	33.2 $\pm$ 1.7	55.9 $\pm$ 1.9	65.0

[†] We provide a one-shot demonstration for Qwen2.5-7B-Instruct in ALFWorld evaluation, as it fails to generate valid tool call format in the environment.

AgentRL 训练的模型在综合性能上达到了新的 SOTA 水平，全面超越了当前最强的闭源和开源基线。

在五个任务的平均成功率上，AGENTRL 训练的 32B 模型达到了 **70.4%** 的新高度。与原始的 Qwen2.5-Instruct 模型相比，RL 训练带来了巨大且一致的性能提升（例如，32B 模型的平均成功率从 37.2% 提升至 70.4%）。更引人注目的是，**所有尺寸**的 AgentRL 模型（从 3B 到 32B）在平均性能上都**稳定地**优于包括 **GPT-5**、**Claude-Sonnet-4 Thinking** 和 **DeepSeek-R1** 在内的顶级对手。

2.2 多任务 vs. 单任务

Table 4: Multi-Task vs. Single-Task with Qwen2.5-14B-Instruct.

Model	ALFWorld	DB	KG	OS	Webshop	AVG
AGENTRL-ALFWorld	89.7 $\pm$ 1.6	49.7 $\pm$ 1.6	22.3 $\pm$ 3.1	33.7 $\pm$ 3.1	15.9 $\pm$ 0.5	42.3
AGENTRL-DB	0.2 $\pm$ 0.5	73.9 $\pm$ 0.7	26.2 $\pm$ 1.7	43.1 $\pm$ 1.3	16.0 $\pm$ 0.9	31.9
AGENTRL-KG	4.6 $\pm$ 1.1	57.6 $\pm$ 0.8	72.2 $\pm$ 1.5	40.3 $\pm$ 2.4	19.5 $\pm$ 2.0	38.8
AGENTRL-OS	5.7 $\pm$ 1.2	58.2 $\pm$ 1.2	25.3 $\pm$ 1.6	39.8 $\pm$ 1.8	22.0 $\pm$ 2.3	30.2
AGENTRL-Webshop	0.0 $\pm$ 0.0	57.9 $\pm$ 2.6	30.7 $\pm$ 2.2	40.1 $\pm$ 0.7	60.3 $\pm$ 1.3	37.8
Best of Five Models Above	89.7 $\pm$ 1.6	73.9 $\pm$ 0.7	72.2 $\pm$ 1.5	43.1 $\pm$ 1.3	60.3 $\pm$ 1.3	67.8
AGENTRL (One Model)	91.5 $\pm$ 0.9	72.2 $\pm$ 0.9	72.8 $\pm$ 1.8	43.6 $\pm$ 1.9	58.5 $\pm$ 1.2	67.7

多任务训练能够培养出一个**性能可与专家模型集合媲美**的单一通用模型，同时避免了单任务学习带来的泛化能力缺失。

在其特定训练任务上表现优异，但一旦面临其他任务，性能便会急剧下降，表现出严重的**过拟合和缺乏泛化性**。AgentRL 训练的**单一 14B 模型**在五个任务上的平均成功率达到了 **67.7%**。这一成绩几乎与一个理论上的“**梦之队**”——即由五个在各自领域表现最佳的单任务专家模型组成的集合——的平均性能（**67.8%**）持平。

这证明了 AgentRL 的多任务训练范式能够有效地让模型**习得可迁移的通用技能**，实现了“**鱼与熊掌兼得**”，在不牺牲各任务峰值性能的前提下，构建了一个强大的通用智能体。

2.3 泛化能力

	nonlive	live		
Qwen2.5-32B-Instruct	86.0 $\pm$ 0.2	77.4 $\pm$ 0.1	16.2 $\pm$ 0.8	59.9 $\pm$ 1.5
AGENTRL w/ Qwen2.5-Instruct-32B	85.8 $\pm$ 0.2 ↓0.2	79.3 $\pm$ 0.2 ↑1.9	19.2 $\pm$ 0.8 ↑3.0	61.4 $\pm$ 1.5


AgentRL 训练能够显著提升模型在**未见任务**上的泛化能力，尤其是在需要多轮交互的复杂场景中。在 **BFCL-v3** 基准上对模型进行评估，该基准在训练过程中完全未被使用。

AgentRL 训练后的模型，在 BFCL-v3 的**多轮次任务**上表现出显著的性能提升，同时在单轮次任务上也有稳健的增益。这表明 AgentRL 不仅仅是让模型“记住”了训练任务的解法，而是真正提升了其底层的、可泛化的**函数调用和规划能力**。

3. 消融研究

Table 6: Ablation on cross-policy sampling and task advantage normalization.

Method	AF	DB	KG	OS	WS	AVG
AGENTRL-14B	93.1 $\pm$ 0.5	64.0 $\pm$ 0.5	67.7 $\pm$ 2.0	45.1 $\pm$ 2.0	55.0 $\pm$ 0.7	65.0
- cross sampling	91.9 $\pm$ 1.2	61.6 $\pm$ 1.0	55.7 $\pm$ 1.4	39.7 $\pm$ 2.3	54.5 $\pm$ 1.3	60.7
- task adv. norm	91.1 $\pm$ 0.9	62.6 $\pm$ 0.7	54.7 $\pm$ 1.6	38.0 $\pm$ 2.0	50.6 $\pm$ 1.7	59.4



(a) Cross-Policy Sampling in KG. (b) Task Adv. Norm. in ALFWorld. (c) Average over 5 environments.

Figure 7: Ablation studies. (c): The combined effect of Cross-Policy Sampling and Task Advantage Normalization, averaged over five environments.

3.1 跨策略采样的影响

图表 6 以及图 7a 所示，移除跨策略采样后，模型平均性能出现**明显下降**。这种性能损失在 KG（知识图谱）这类**开放式、探索空间巨大**的环境中尤为严重。训练曲线显示，启用了该策略的模型能**更快地达到性能瓶颈**。

跨策略采样是提升模型探索能力、扩展其能力边界的关键。

3.2 任务优势归一化的影响

图表 6 以及图 7b 所示，移除任务优势归一化后，不仅最终性能**显著降低**，训练过程也变得**极不稳定**，在某些任务上出现剧烈震荡。这表明模型在没有该模块的情况下，无法平衡不同任务的学习，导致学习过程顾此失彼。

所属专栏 · 2025-12-04 14:14 更新



论文

熵基跃迁

142 篇内容 · 1871 赞同

订阅

最热内容 · ARPO：利用高熵不确定性，更高效的进行 Agentic RL Rollout

发布于 2025-11-01 11:10 · 北京

RL AI infra Agent

官方 AI 助手 写作/绘图/编程/翻译



理性发言，友善互动




☐ 同时发布到想法

发布



还没有评论，发表第一个评论吧

推荐阅读



Menger:大规模分布式强化学习架构

AI 研习社 发表于 AI 研习社 ...



【IEEE-RAL】LAMARL：大语言模型辅助的多智能体强化学...

赵世钰-西湖大学

【硬核书】迁移学习多智能体强化学习系统，131 页 pdf

学习解决顺序决策任务是困难的。人类花了数年时间，基本上以一种随机的方式探索环境，直到他们能够推理，解决困难的任务，并与其他人合作实现一个共同的目标。人工智能智能体在这方面和人类很...

专知

【硬核书】迁移学习多智能体强化学习系统，131 页 pdf

学习解决顺序决策任务是困难的。人类花了数年时间，基本上以一种随机的方式探索环境，直到他们能够推理，解决困难的任务，并与其他人合作实现一个共同的目标。人工智能智能体在这方面和人类很...

专知